Model XGBoots Preprocessing

อธิบายการทำ Preprocessing

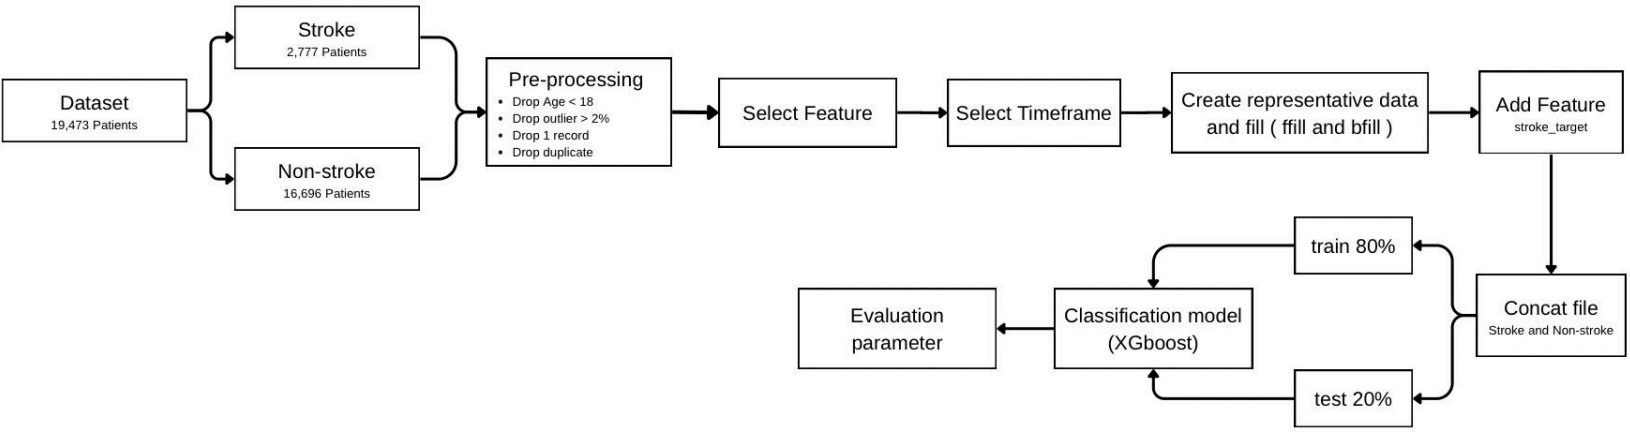

รูปที่ 1 Flow chart preprocessing

1 . Dataset จำนวนผู้ป่วย 58-67 รพ.โชคชัย

- มีข้อมูลทั้งหมด 262,140 Records
- มีผู้ป่วยทั้งหมด 19,473 คน
    - Stroke 2,777 คน
    - Non-Stroke 16,696 คน

หมายเหตุ 1. แยกผู้ป่วยตามวินิจฉัยหลัก (ICD - 10) พบว่า
ผู้ป่วย Stroke จะผลวินิจฉัยหลักอยู่ที่ I60 - I699
2. เราพบ record ที่ว่างเปล่าจำนวน 16164 records จึงทำการ drop ทิ้งจึงเหลือ 245976 ที่ใช้งานได้

โดยสามารถแสดงจำนวนผู้ป่วยในแต่ละ Time frame ดังตารางที่ 1

ช่วงเวลา (เดือน)	จำนวนผู้ป่วย Stroke	จำนวนผู้ป่วย Non-Stroke
3-6	414	7580
6-9	394	6250
9-12	370	6944
12-15	337	5694
15-18	348	5159
18-21	324	4499
21-24	294	4748
24-27	280	4988

ตารางที่ 1 จำนวนผู้ป่วยในแต่ละ Time frame

Feature ทั้งหมด ใน Data set ดังตารางที่ 2

feature	Missing data Stroke	Missing data Non Stroke	All Missing data	Type	Description
hosp	**0.00%**	0.00%	0.00%	Categorical	รหัสโรงพยาบาล
hn	0.00%	0.00%	0.00%	Categorical	รหัสผู้ป่วย
vn	0.00%	0.00%	0.00%	Categorical	Visit Number (รหัสการเข้ารับบริการ)
vstdate	0.00%	0.00%	0.00%	Categorical	วันที่เข้ารับบริการ
sex	0.00%	0.00%	0.00%	Categorical	เพศ (ชาย/หญิง)
age	0.00%	0.00%	0.00%	Numerical	อายุ (ปี)
height	2.72%	2.89%	2.87%	Numerical	ส่วนสูง (cm)
bw	1.83%	2.22%	2.16%	Numerical	น้ำหนัก (kg)
bmi	3.16%	3.72%	3.63%	Numerical	ดัชนีมวลกาย
smoke	7.30%	11.24%	10.64%	Categorical	ประวัติการสูบบุหรี่

drinking	7.32%	11.25%	10.65%	Categorical	ประวัติการดื่มแอลกอฮอล์
bps	5.30%	8.46%	7.98%	Numerical	ความดันช่วงบน (Systolic)
bpd	5.30%	8.47%	7.98%	Numerical	ความดันช่วงล่าง (Diastolic)
waist	6.94%	10.04%	9.57%	Numerical	รอบเอว (cm)
กรุ๊ปเลือด	0.32%	0.29%	0.29%	Categorical	หมู่เลือด (A, B, AB, O)
NIHSS	99.66%	100.00%	99.95%	Numerical	แบบประเมินความรุนแรงของโรคหลอดเลือดสมอง (NIH Stroke Scale)
HDL	79.54%	69.73%	71.22%	Numerical	คอเลสเตอรอลชนิดดี
LDL	79.39%	69.59%	71.08%	Numerical	คอเลสเตอรอลชนิดไม่ดี
Triglyceride	79.49%	69.67%	71.17%	Numerical	ไตรกลีเซอไรด์
Cholesterol	78.46%	68.97%	70.42%	Numerical	คอเลสเตอรอลรวม
CRP	99.90%	99.88%	99.88%	Numerical	C-Reactive Protein (ตัวบ่งชี้การอักเสบ)
EKG	0.00%	0.00%	0.00%	Categorical	ผลตรวจคลื่นไฟฟ้าหัวใจ
AF	13.12%	16.84%	16.27%	Categorical	ภาวะหัวใจเต้นผิดจังหวะแบบ Atrial Fibrillation
CT	0.00%	0.00%	0.00%	Categorical	ผลตรวจ CT Scan สมอง
HbA1C	93.24%	90.60%	91.01%	Numerical	ระดับน้ำตาลเฉลี่ยในเลือดย้อนหลัง 3 เดือน
FBS	80.35%	73.29%	74.36%	Numerical	น้ำตาลในเลือดขณะอดอาหาร
eGFR	73.04%	66.79%	67.74%	Numerical	ประมาณค่าการทำงานของไต
Creatinine	71.13%	64.28%	65.33%	Numerical	ค่าการทำงานของไต (สารเคมีในเลือด)
albuminurine	88.67%	85.31%	85.82%	Numerical / Categorical	ตรวจหาปริมาณโปรตีนในปัสสาวะ
Proliferativediabeticretinopathy	0.00%	0.00%	0.00%	Categorical	ภาวะเบาหวานขึ้นจอตาระยะรุนแรง
NPDR	0.00%	0.00%	0.00%	Categorical	Non-Proliferative Diabetic Retinopathy

					(เบาหวานขึ้นจอตาระยะเริ่มต้น)
comascoreE	86.04%	95.70%	94.23%	Numerical	GCS - การลืมตา (Eye)
comascoreM	86.04%	95.70%	94.23%	Numerical	GCS - การตอบสนองด้านการเคลื่อนไหว (Motor)
comascoreV	86.04%	95.70%	94.23%	Numerical	GCS - การตอบสนองด้วยเสียงพูด (Verbal)
PrincipleDiagnosis	0.00%	0.00%	0.00%	Categorical	รหัสโรคหลักที่ได้รับการวินิจฉัย
ComobidityDiagnosis	28.31%	27.30%	27.45%	Categorical	โรคร่วมที่ตรวจพบเพิ่มเติม
Complication	99.16%	99.14%	99.20%	Categorical	ภาวะแทรกซ้อนระหว่างการรักษา
FirstDiagDate	4.42%	97.89%	83.64%	Categorical	วันที่วินิจฉัยโรคหลอดเลือดสมองครั้งแรก
MI	0.00%	0.00%	0.00%	Categorical	ประวัติกล้ามเนื้อหัวใจขาดเลือด (Myocardial Infarction)
วันที่ฉีด_ประเภทวัคซีน	35.97%	25.07%	26.73%	Categorical	วันที่และประเภทวัคซีนที่ได้รับ
จำนวนเข็ม	35.97%	25.07%	26.73%	Numerical	จำนวนโดสที่ได้รับ
Covid	80.26%	78.01%	78.35%	Categorical	ได้รับวัคซีน COVID-19 หรือไม่
Influenza	94.62%	92.87%	93.14%	Categorical	ได้รับวัคซีนไข้หวัดใหญ่หรือไม่
ตำบล	6.47%	7.81%	7.60%	Categorical	ตำบลที่อยู่ของผู้ป่วย
ยาที่ได้รับ	45.28%	52.00%	50.97%	Categorical / Text	รายการยาที่ได้รับระหว่างการรักษา

ตารางที่ 2 Feature ทั้งหมด ใน Data set

โดยเมื่อนับประเภทของขอมูลพบว่า ดังไฟล์ https://shorturl.asia/kPSr4

feature	Missing data Stroke	Missing data Non Stroke	All Missing data	Type	Description
hosp	**0.00%**	0.00%	0.00%	Categorical	Hospital code
hn	0.00%	0.00%	0.00%	Categorical	Patient ID
vn	0.00%	0.00%	0.00%	Categorical	Visit Number
vstdate	0.00%	0.00%	0.00%	Categorical	Visit date
sex	0.00%	0.00%	0.00%	Categorical	Gender
age	0.00%	0.00%	0.00%	Numerical	Age (years)
height	2.72%	2.89%	2.87%	Numerical	Height (cm)
bw	1.83%	2.22%	2.16%	Numerical	Weight (kg)
bmi	3.16%	3.72%	3.63%	Numerical	Body Mass Index
smoke	7.30%	11.24%	10.64%	Categorical	Smoking history
drinking	7.32%	11.25%	10.65%	Categorical	Alcohol consumption history
bps	5.30%	8.46%	7.98%	Numerical	Systolic Blood Pressure
bpd	5.30%	8.47%	7.98%	Numerical	Diastolic Blood Pressure

waist	6.94%	10.04%	9.57%	Numerical	Waist circumference (cm)
blood group	0.32%	0.29%	0.29%	Categorical	Blood group (A, B, AB, O)
NIHSS	99.66%	100.00%	99.95%	Numerical	NIH Stroke Scale score
HDL	79.54%	69.73%	71.22%	Numerical	High-density lipoprotein (HDL)
LDL	79.39%	69.59%	71.08%	Numerical	Low-density lipoprotein (LDL)
Triglyceride	79.49%	69.67%	71.17%	Numerical	Triglycerides
Cholesterol	78.46%	68.97%	70.42%	Numerical	Total cholesterol
CRP	99.90%	99.88%	99.88%	Numerical	C-Reactive Protein (inflammation marker)
EKG	0.00%	0.00%	0.00%	Categorical	Electrocardiogram results
AF	13.12%	16.84%	16.27%	Categorical	Atrial Fibrillation
CT	0.00%	0.00%	0.00%	Categorical	Brain CT scan results
HbA1C	93.24%	90.60%	91.01%	Numerical	Glycated hemoglobin (3-month avg glucose)
FBS	80.35%	73.29%	74.36%	Numerical	Fasting Blood Sugar
eGFR	73.04%	66.79%	67.74%	Numerical	Estimated Glomerular Filtration Rate (kidney function)
Creatinine	71.13%	64.28%	65.33%	Numerical	Creatinine (kidney function marker)
albuminurine	88.67%	85.31%	85.82%	Numerical / Categorical	Protein in urine
Proliferativediabeticr etinopathy	0.00%	0.00%	0.00%	Categorical	Severe diabetic eye disease
NPDR	0.00%	0.00%	0.00%	Categorical	Non-proliferative diabetic retinopathy
comascoreE	86.04%	95.70%	94.23%	Numerical	Glasgow Coma Scale - Eye Response
comascoreM	86.04%	95.70%	94.23%	Numerical	GCS - Motor Response
comascoreV	86.04%	95.70%	94.23%	Numerical	GCS - Verbal Response
PrincipleDiagnosis	0.00%	0.00%	0.00%	Categorical	Principal diagnosis code

ComobidityDiagnosis	28.31%	27.30%	27.45%	Categorical	Additional comorbidities
Complication	99.16%	99.14%	99.20%	Categorical	Complications during treatment
FirstDiagDate	4.42%	97.89%	83.64%	Categorical	First diagnosis date of stroke
MI	0.00%	0.00%	0.00%	Categorical	Myocardial infarction history
Vaccine Date/Type	35.97%	25.07%	26.73%	Categorical	COVID-19 vaccine type and date
จำนวนเข็ม	35.97%	25.07%	26.73%	Numerical	Number of vaccine doses received
Covid	80.26%	78.01%	78.35%	Categorical	COVID-19 vaccination status
Influenza	94.62%	92.87%	93.14%	Categorical	Influenza vaccination status
Subdistrict	6.47%	7.81%	7.60%	Categorical	Patient's residential subdistrict
Medications	45.28%	52.00%	50.97%	Categorical / Text	Medications administered during treatment

2 . Data Preprocessing

- Drop Age < 18
- Drop 1 record
  หมายเหตุ ผู้ป่วยบางคนข้อมูลน้อยเกินไป
- Drop duplicate
  หมายเหตุ มีข้อมูลบ้าง records ซ้ำกัน

หลังจาก Drop Age < 18 , Drop 1 record , Drop duplicate เราจะเหลือข้อมูล ดังตารางที่ 3

ผู้ป่วย	จำนวนผู้ป่วย	record
Stroke	2192	32876
Non-Stroke	14007	191297

ตารางที่ 3 จำนวนผู้ป่วยหลังจากทำ 3 ขั้นตอน

- Drop outlier ที่มี % ที่สูง โดยเราทำการ Drop outlier หลังจากทำขั้นตอนก่อนหน้านี้พบว่า

การ คำนวนหา outlier เราได้ใช้หลัก IQR (Interquartile Range) ในการตรวจจับ outliers หรือ ค่าผิดปกติ ทางสถิติจากข้อมูลในแต่ละ Feature ที่เป็นเชิงตัวเลข โดยเริ่มจาก

1. เริ่มจากการแปลงข้อมูลเป็นตัวเลข
2. ลบข้อมูลที่มี missing value ชั่วคราวเพื่อให้สามารถคำนวณได้
3. คำนวณ IQR (Interquartile Range) เพื่อหาขอบเขตของข้อมูลที่ถือว่า ปกติ โดย
    a. Q1 คือ ค่าที่อยู่ตำแหน่ง 25% ของข้อมูล (quartile แรก)
    b. Q3 คือ ค่าที่อยู่ตำแหน่ง 75% ของข้อมูล (quartile สาม)
    c. IQR คือ ช่วงกระจายระหว่าง Q1 ถึง Q3 = Q3 - Q1
4. คำนวณหาขอบเขตของค่า outlier โดยใช้
    a. lower_bound = Q1 - 1.5 * IQR (คือค่าต่ำสุดที่ข้อมูลในช่วงปกติ)
    b. upper_bound = Q3 + 1.5 * IQR (คือค่าสูงสุดที่ข้อมูลในช่วงปกติ)
5. คำนวณหา % outlier จาก (จำนวนข้อมูลที่เป็น outlier / จำนวนทั้งหมดของข้อมูลนั้น) * 100

stroke						
feature	All (%)	Records	ค่า min ของ feature	ค่า max ของ feature	ค่า min ของ outlier	ค่า max ของ outlier
bmi	12.64%	4520	0.00	5000000.00	0.00	5000000.00
FBS	8.35%	614	15.30	487.00	15.30	487.00
bpd	7.18%	2512	0.00	1132.00	0.00	1132.00
bps	8.30%	2903	0.00	14462.00	0.00	14462.00
HDL	1.92%	146	14.00	161.00	14.00	161.00
LDL	1.73%	131	-30.00	337.00	-30.00	337.00
age	0.14%	50	20.00	101.00	20.00	28.00
eGFR	0.03%	3	1.06	202.58	161.44	202.58

ตารางที่ 4 เปอร์เซ็นต์ outlier โดยใช้ IQR ใน stroke ก่อน drop

non stroke						
feature	All (%)	Records	ค่า min ของ feature	ค่า max ของ feature	ค่า min ของ outlier	ค่า max ของ outlier
bmi	5.07%	10034	0.00	1250000.00	0.00	1250000.00
FBS	8.67%	4747	2.00	595.00	2.00	595.00
bpd	6.04%	11382	0.00	8109.00	0.00	8109.00
bps	7.83%	14758	0.00	15791.00	0.00	15791.00
HDL	1.83%	1132	11.00	196.00	11.00	196.00
LDL	1.22%	744	1.00	1462.00	1.00	1462.00
age	0.23%	480	18.00	107.00	18.00	107.00
eGFR	0.71%	482	1.00	186.21	1.00	186.21

ตารางที่ 4 เปอร์เซ็นต์ outlier โดยใช้ IQR ใน non stroke ก่อน drop

ทดลองการคำนวนหา outlier โดยกำหนดขอบเขตช่วง ±5 SD ถ้าค่าเฉลี่ยข้อข้อมูลนั้นเกินจะถือว่าเป็น Outlier
โดยเริ่มจาก

1. เริ่มจากการแปลงข้อมูลเป็นตัวเลข
2. ลบข้อมูลที่มี missing value ชั่วคราวเพื่อให้สามารถคำนวณได้
3. หาค่ากลางและค่าการกระจายตัว (std) ของแต่ละ feature
4. คำนวณหาขอบเขตของค่า outlier โดยใช้
    a. lower_bound = mean - 5 * std (คือค่าต่ำสุดที่ข้อมูลในช่วงปกติ)
    b. upper_bound = mean + 5 * std (คือค่าสูงสุดที่ข้อมูลในช่วงปกติ)
5. คำนวณหา % outlier จาก (จำนวนข้อมูลที่เป็น outlier / จำนวนทั้งหมดของข้อมูลนั้น) * 100

stroke						
feature	All (%)	Records	min value of feature	max value of feature	min outlier	max outlier
bmi	0.27%	96	0.00	5000000.00	289000.00	5000000.00
FBS	0.58%	43	15.30	487.00	348.00	487.00
bpd	0.01%	4	0.00	8109.00	188.00	1132.00
bps	0.00%	1	0.00	15791.00	14462.00	14462.00
HDL	0.13%	10	11.00	196.00	131.00	161.00
LDL	0.03%	2	-30.00	337.00	309.00	337.00
age	0.00%	0	20.00	101.00	ไม่มี outlier	ไม่มี outlier
eGFR	0.01%	1	1.06	202.58	202.58	202.58

ตารางที่ 4 เปอร์เซ็นต์ outlier โดยใช้ ±5 SD ใน stroke ก่อน drop

non stroke						
feature	All (%)	Records	min value of feature	max value of feature	min outlier	max outlier
bmi	0.14%	283	0.00	1250000.00	247000.00	1250000.00
FBS	0.70%	381	2.00	595.00	297.00	595.00
bpd	0.01%	10	0.00	8109.00	400.00	8109.00
bps	0.00%	45	0.00	15791.00	400.00	15791.00
HDL	0.07%	41	11.00	196.00	125.00	196.00

non stroke						
feature	All (%)	Records	min value of feature	max value of feature	min outlier	max outlier
bmi	0.14%	283	0.00	1250000.00	247000.00	1250000.00
FBS	0.70%	381	2.00	595.00	297.00	595.00
bpd	0.01%	10	0.00	8109.00	400.00	8109.00
bps	0.00%	45	0.00	15791.00	400.00	15791.00
LDL	0.02%	14	1.00	1462.00	310.00	1462.00
age	0.00%	0	18.00	107.00	ไม่มี outlier	ไม่มี outlier
eGFR	0.00%	0	1.00	186.21	ไม่มี outlier	ไม่มี outlier

ตารางที่ 4 เปอร์เซ็นต์ outlier โดยใช้ ±5 SD ใน non stroke ก่อน drop

เปรียบเทียบการทดสอบ drop outlier ระหว่างใช้หลัก IQR (Interquartile Range) กับกำหนดขอบเขตช่วง ±5 SD

หมายเหตุ จะเห็นได้ว่า Feature : bmi , bpd , bps มี outlier ที่สูงเราจึงทำการ drop ทิ้ง เราจะไม่ drop FBS เนื่องจากอาจบ่งบอกถึงโรคเบาหวานร่วมด้วยได้ จะเหลือข้อมูลดังตารางที่ 5

ผู้ป่วย	จำนวนผู้ป่วยก่อน drop	จำนวนผู้ป่วยหลัง drop
Stroke	2192	2028
Non-Stroke	14007	13217

ตารางที่ 5 จำนวนผู้ป่วยก่อนและหลัง drop outlier โดยใช้ IQR

โดยสามารถแสดงจำนวนผู้ป่วยในแต่ละ Time frames หลังทำ Data Preprocessing ที่ drop outlier โดยใช้ IQR ดังตารางที่ 6

ช่วงเวลา (เดือน)	จำนวนผู้ป่วย Stroke	จำนวนผู้ป่วย Non-Stroke
3-6	275	6866
6-9	255	5550

9-12	257	6186
12-15	219	5033
15-18	222	4528
18-21	198	3907
21-24	178	4004
24-27	178	4270

ตารางที่ 6 จำนวนผู้ป่วยแต่ละ Time frames หลังทำ Data Preprocessing

feature	Stroke (records)	Stroke (%)	Non-Stroke (records)	Non-Stroke (%)	All (records)	All (%)
smoke	563	2.29%	5437	3.60%	6000	3.41%
LDL	19448	79.22%	109865	72.67%	129313	73.59%
FBS	19503	79.45%	113802	75.28%	133305	75.86%
drinking	569	2.32%	5454	3.61%	6023	3.43%
eGFR	17695	72.08%	103740	68.62%	121435	69.11%
HDL	19492	79.40%	110098	72.83%	129590	73.75%
AF	2690	10.96%	22835	15.11%	25525	14.53%

ตารางที่ 7 จำนวน missing value หลังทำ Data Preprocessing (IQR)

ผู้ป่วย	จำนวนผู้ป่วยก่อน drop	จำนวนผู้ป่วยหลัง drop
Stroke	2192	2189
Non-Stroke	14007	13749

ตารางที่ 8 จำนวนผู้ป่วยก่อนและหลัง drop outlier โดยใช้ ±5 SD

โดยสามารถแสดงจำนวนผู้ป่วยในแต่ละ Time frames หลังทำ Data Preprocessing ที่ drop outlier โดยใช้ขอบเขตช่วง ±5 SD ดังตารางที่ 8

ช่วงเวลา (เดือน)	จำนวนผู้ป่วย Stroke	จำนวนผู้ป่วย Non-Stroke
3-6	368	7455
6-9	357	6116
9-12	330	6688
12-15	295	5512

15-18	295	5006
18-21	289	4335
21-24	253	4475
24-27	240	4729

ตารางที่ 9 จำนวนผู้ป่วยแต่ละ Time frames หลังทำ Data Preprocessing โดยใช้ขอบเขตช่วง ±5 SD

feature	Stroke (records)	Stroke (%)	Non-Stroke (records)	Non-Stroke (%)	All (records)	All (%)
smoke	619	2.03%	5737	3.33%	6356	3.13%
LDL	24831	81.37%	125745	73.01%	150576	74.27%
FBS	24866	81.49%	130029	75.50%	154895	76.40%
drinking	625	2.05%	5755	3.34%	6380	3.15%
eGFR	22556	73.92%	118317	68.70%	140873	69.48%
HDL	24879	81.53%	126007	73.16%	150886	74.42%
AF	3643	11.94%	26690	15.50%	30333	14.96%

ตารางที่ 7 จำนวน missing value หลังทำ Data Preprocessing (±5 SD)

3 . Select Feature โดย Feature ที่เราเลือกใช้ดังตารางที่ 7

Feature	All Missing data	Type	Description
hn	0.00%	Categorical	Patient ID
vstdate	0.00%	Categorical	Visit date
sex	0.0%	Categorical 1 = male , 2 = female	Gender
Age	0.00%	Numerical	Age (years)
Bmi	3.63%	Numerical	Body Mass Index
Smoke	10.64%	Categorical Non-smoker = 1 , Former smoker = 2 , Current smoker = 3	Smoking history
Drinking	10.65%	Categorical Non-drinker = 1 , Current drinker = 2 , Former drinker = 3	Alcohol consumption history
Bpd	7.98%	Numerical	Diastolic Blood Pressure
Bps	7.98%	Numerical	Systolic Blood Pressure
LDL	71.08%	Numerical	Low-density lipoprotein
FBS	74.36%	Numerical	Fasting Blood Sugar
eGFR	67.74%	Numerical	Estimated Glomerular Filtration Rate
HDL	71.22%	Numerical	High-density lipoprotein
AF	16.27%	Categorical no = 1 , yes = 2	Atrial Fibrillation

ตารางที่ 7 Feature และ ข้อมูลของ Feature

อธิบาย Feature ที่ส่งผลต่อการเกิดโรค Stroke

อายุ (Age): ความเสี่ยงโรคหลอดเลือดสมองจะเพิ่มขึ้นประมาณ 2% ต่อปี โดยเฉพาะในผู้ที่มีอายุตั้งแต่ 65 ปีขึ้นไป โดยอัตราการเกิดโรคหลอดเลือดสมองจะสูงขึ้นในผู้สูงอายุในทุกประเภทของโรคหลอดเลือดสมอง.

เพศ (Sex) (ชาย = 1, หญิง = 2): ในช่วงวัยหนุ่มสาว ผู้ชายมีภาระโรคหลอดเลือดสมองมากกว่า แต่ในช่วงวัยกลางคนและผู้สูงอายุ ผู้หญิงกลับมีความเสี่ยงมากกว่า โดยเฉพาะผู้หญิงสูงวัยที่มีอัตราการเสียชีวิตและผลลัพธ์จากโรคที่แย่กว่าผู้ชาย.

ดัชนีมวลกาย (BMI): ความเสี่ยงโรคหลอดเลือดสมองสัมพันธ์ในทางบวกกับค่า BMI โดยผู้ที่มีค่า BMI สูง (น้ำหนักเกินหรืออ้วน) จะมีความเสี่ยงสูงกว่า (อัตราส่วนความเสี่ยง RR = 1.25 และ 1.47) โดยเฉพาะในผู้ชายและผู้ป่วยโรคหลอดเลือดสมองตีบ (ischemic stroke).

สถานะการดื่มแอลกอฮอล์ (Alcohol Consumption Status) (ไม่ดื่ม = 1, ดื่ม = 2, เคยดื่ม = 3): การดื่มแอลกอฮอล์เกิน 60 กรัมต่อวันจะเพิ่มความเสี่ยงของโรคหลอดเลือดสมองตีบและแตก ขณะที่การดื่มน้อยกว่า 12 กรัมต่อวันสามารถลดความเสี่ยงของโรคหลอดเลือดสมองทุกประเภทและชนิดตีบได้.

สถานะการสูบบุหรี่ (Smoking Status) (ไม่สูบ = 1, เคยสูบ = 2, สูบ = 3): การสูบบุหรี่เพิ่มความเสี่ยงของโรคหลอดเลือดสมอง โดยผู้ที่สูบบุหรี่ในปัจจุบันมีความเสี่ยงสูง (อัตราส่วนโอกาส OR = 1.92) และการได้รับควันบุหรี่โดยทางอ้อม (passive smoking) เพิ่มความเสี่ยงถึง 45%.

ความดันโลหิต (BPS, BPD): ความดันโลหิตสูงเพิ่มความเสี่ยงของโรคหลอดเลือดสมอง โดยความเสี่ยงจะเพิ่มขึ้น 35% ทุก ๆ การเพิ่มขึ้น 10 mmHg ของความดันซิสโตลิก (systolic blood pressure).

คอเลสเตอรอล (HDL, LDL): ระดับของไขมันความหนาแน่นต่ำขนาดเล็ก (small dense LDL หรือ sdLDL) มีความสัมพันธ์กับความเสี่ยงที่เพิ่มขึ้นของโรคหลอดเลือดสมองตีบเฉียบพลัน (acute ischemic stroke) และการเสียชีวิตในระยะสั้นหลังจากเกิดโรคดังกล่าว.

ระดับน้ำตาลในเลือด (FBS): ระดับน้ำตาลในเลือดที่สูงขึ้นสามารถเพิ่มความเสี่ยงของโรคหลอดเลือดสมองตีบได้ โดยความเสี่ยงจะเพิ่มขึ้นอย่างต่อเนื่อง แม้ระดับน้ำตาลจะยังไม่ถึงเกณฑ์ที่ใช้วินิจฉัยว่าเป็นเบาหวานก็ตาม.

ภาวะหัวใจห้องบนสั่นพลิ้ว (Atrial Fibrillation หรือ AF) (ไม่มี = 1, มี = 2): การมีภาวะหัวใจห้องบนสั่นพลิ้วเพิ่มความเสี่ยงของโรคหลอดเลือดสมอง เนื่องจากลิ่มเลือดสามารถเคลื่อนจากหัวใจไปยังสมองได้.

ค่าการทำงานของไต (eGFR): การมีโปรตีนหรืออัลบูมินในปัสสาวะเป็นตัวพยากรณ์ความเสี่ยงของโรคหลอดเลือดสมองที่ดีมากในผู้ที่มีภาวะไตผิดปกติ โดยผู้ที่มีโปรตีนหรืออัลบูมินในปัสสาวะจะมีความเสี่ยงสูงขึ้นในการเกิดโรคหลอดเลือดสมอง.

ค้นพบข้อมูลในบาง feature ที่ยังรอการแก้ไขดังตารางที่ 8

Feature	ข้อมูลผิดปกติ	สถานะ
HDL	"56<R>" ,"80(R)","90 R" "กินข้าวแล้ว" "36 milky serum"	R แก้ไขแล้ว
LDL	"TG > 400 ไม่สามารถรายงาน LDL ได้", "ไม่รายงาน LDL-C เนื่องจาก TG > 400 mg/dL" "ไม่รายงาน LDL-C เนื่องจาก HDL-C >400mg/dL" "Direct LDL" ("116.50 Direct LDL") "กินข้าวแล้ว"	ยัง

FBS	“86 <ทำจาก blood clot>”, “เลือด clot”, “FBS clot”, “clot”, “136 <ตรวจจาก blood clot>” “ตรวจไม่ได้เพราะclot” DTX=139 แลนเกิน" , "lanเกิน" “FBS ได้ค่าต่ำ ไม่รายงานผล (มาส่ง lab 15.30 น.)” “ไม่มี tube” “85 Hemolysis 1+” “มี tube น้ำตาลคนนี้ 2 หลอด ออกผลไม่ได้” '508ค่าวิกฤต', '438ค่าวิกฤต', '51ค่าวิกฤต', '41ค่าวิกฤต' “กินข้าวมาแล้ว”, “คนไข้ทานข้าวมาแล้ว” “ไม่มี tube เลือด (Lan เกิน)” “ส่งเลือดมาใหม่แล้ว”	ยัง

ตารางที่ 8 ข้อมูลผิดปกติ

จำนวนผู้ป่วยที่ พบข้อมูลที่ผิดปกติใน feature ดังกล่าวดังตารางที่ 9

feature	ข้อมูลหลัก (คน)	ข้อมูลหลัง Data Preprocessing (คน)
HDL	251	181
LDL	793	707
FBS	625	0

จำนวนผู้ป่วยที่ไม่ซ้ำ	1777	872

ตารางที่ 9 จำนวนผู้ป่วยที่พบข้อมูลที่ผิดปกติใน feature ดังกล่าว

HDL		
ประเภทข้อมูลผิดปกติ	ข้อมูลหลัก (คน)	ข้อมูลหลัง Data Preprocessing (คน)
กินข้าว	1	1
milky serum	1	1
(R)	242	165
<R>	7	4

ตารางที่ 10 จำนวนผู้ป่วยที่พบข้อมูลที่ผิดปกติใน HDL

LDL		
ประเภทข้อมูลผิดปกติ	ข้อมูลหลัก (คน)	ข้อมูลหลัง Data Preprocessing (คน)
TG สูงผิดปกติ (TG>400)	757	554
ไม่สามารถคำนวณ/รายงานได้	221	144
ไม่รายงาน LDL โดยตรง	418	311

LDL พิเศษ	10	8
ตัวแปร LDL อื่นๆ	198	126
ข้อความไม่ระบุเหตุผล	645	461

ตารางที่ 11 จำนวนผู้ป่วยที่พบข้อมูลที่ผิดปกติใน LDL

FBS		
ประเภทข้อมูลผิดปกติ	ข้อมูลหลัก (คน)	ข้อมูลหลัง Data Preprocessing (คน)
ผลตรวจไม่ได้ / รายงานไม่ได้	115	0
กินอาหารก่อนตรวจ	3	0
ใช้ DTX ตรวจ	16	0
ค่าผิดปกติ (R), <R>	548	0
ค่าวิกฤต	124	0

ตารางที่ 12 จำนวนผู้ป่วยที่พบข้อมูลที่ผิดปกติใน FBS

เมื่อตรวจสอบ missing value แต่ละFeature ในแต่ละ Time frame ดังตารางที่ 13

ช่วงเวลา (เดือน)	sex	age	bmi	smoke	LDL	FBS	drinking	eGFR	HDL	bpd	AF	bps
3-6	0%	0%	0%	1.33%	73.87%	76.85%	1.32%	64.96%	74.25%	0%	22.29%	0%
6-9	0%	0%	0%	4.64%	74.31%	76.36%	4.66%	64.08%	74.50%	0%	20.71%	0%
9-12	0%	0%	0%	7.75%	66.83%	69.43%	7.88%	58.41%	66.99%	0%	21.55%	0%

12-15	0%	0%	0%	3.49%	68.97%	71.99%	3.49%	60.73%	69.05%	0%	19.05%	0%
15-18	0%	0%	0%	2.34%	69.91%	73.45%	2.34%	62.14%	69.98%	0%	16.66%	0%
18-21	0%	0%	0%	1.93%	74.93%	77.02%	1.95%	67.28%	75.13%	0%	14.40%	0%
21-24	0%	0%	0%	8.08%	67.29%	71.82%	8.08%	61.43%	67.39%	0%	15.78%	0%
24-27	0%	0%	0%	9.77%	62.22%	65.86%	9.79%	56.47%	62.20%	0%	16.92%	0%

ตารางที่ 13 missing value แต่ละFeature ในแต่ละ Time frame

4 . Select Timeframe เราทำการเลือกช่วงเวลาเพื่อมาทำนายโดยเราจะใช้ข้อมูลหลังNormalization ดังตารางที่ 14

ช่วงเวลา (เดือน)	จำนวนผู้ป่วย Stroke	จำนวนผู้ป่วย Non-Stroke
3-6	275	6866
6-9	255	5550
9-12	257	6186

12-15	219	5033
15-18	222	4528
18-21	198	3907
21-24	178	4004
24-27	178	4270

ตารางที่ 14 จำนวนผู้ป่วยแต่ละ Time frames หลังทำ Data Preprocessing และ Time frames ที่ใช้

โดยแต่ละ Timeframes ของเรา เราจะใช้ข้อมูล ผู้ป่วย Stroke จาก Timeframes ที่สนใจเช่นเราต้อง
การรู้ว่าอีก 3 เดือนเราจะเป็น Stroke มั้ย โดยเราจะใช้ข้อมูล ผู้ป่วย Stroke ช่วง 3-6 ก่อนที่จะพบโรค Stroke กับ ผู้ป่วย Non-Stroke ช่วง 3-6 เดือนก่อนที่จะไป visit ล่าสุด สามารถอธิบายเพิ่มเติมดังตารางที่ 15

Timeframe (เดือนก่อนก่อนพบ Stroke)	ข้อมูลผู้ป่วย Stroke จาก ช่วงก่อนป่วย	ข้อมูลผู้ป่วย Non-Stroke จากช่วงก่อน visit ล่าสุด	เป้าหมาย

3	ใช้ข้อมูลช่วง 3–6 เดือนก่อนพบว่าเป็น Stroke	ใช้ข้อมูลช่วง 3–6 เดือนก่อนเยี่ยมล่าสุด	เราต้องการรู้ว่าผู้ป่วยจะเป็น Stroke **ในอีก 3 เดือนข้างหน้า** หรือไม่
6	ใช้ข้อมูลช่วง 6–9 เดือนก่อนพบว่าเป็น Stroke	ใช้ข้อมูลช่วง 6–9 เดือนก่อนเยี่ยมล่าสุด	เราต้องการรู้ว่าผู้ป่วยจะเป็น Stroke **ในอีก 6 เดือนข้างหน้า** หรือไม่
9	ใช้ข้อมูลช่วง 9–12 เดือนก่อนพบว่าเป็น Stroke	ใช้ข้อมูลช่วง 9–12 เดือนก่อนเยี่ยมล่าสุด	ต้องการทำนายล่วงหน้า 9 เดือนว่าเสี่ยงเป็น Stroke หรือไม่
12	ใช้ข้อมูลช่วง 12–15 เดือนก่อนพบว่าเป็น Stroke	ใช้ข้อมูลช่วง 12–15 เดือนก่อนเยี่ยมล่าสุด	ต้องการทำนายล่วงหน้า 12 เดือนว่าเสี่ยงเป็น Stroke หรือไม่
15	ใช้ข้อมูลช่วง 15–18 เดือนก่อนพบว่าเป็น Stroke	ใช้ข้อมูลช่วง 15–18 เดือนก่อนเยี่ยมล่าสุด	ทดลอง ทำนายล่วงหน้าในระยะ 15 เดือน
18	ใช้ข้อมูลช่วง 18–21 เดือนก่อนพบว่าเป็น Stroke	ใช้ข้อมูลช่วง 18–21 เดือนก่อนเยี่ยมล่าสุด	ทดลอง ทำนายล่วงหน้าในระยะ 18 เดือน
21	ใช้ข้อมูลช่วง 21–24 เดือนก่อนพบว่าเป็น Stroke	ใช้ข้อมูลช่วง 21–24 เดือนก่อนเยี่ยมล่าสุด	ทดลอง ทำนายล่วงหน้าในระยะ 21 เดือน
24	ใช้ข้อมูลช่วง 24–27 เดือนก่อนพบว่าเป็น Stroke	ใช้ข้อมูลช่วง 24–27 เดือนก่อนเยี่ยมล่าสุด	ทดลอง ทำนายล่วงหน้าในระยะ 24 เดือน

ตารางที่ 15 ความหมาย Time frames

5 . Create representative data and fill (ffill and bfill) เนื่องจากแต่ละ Time frames มีจำนวนที่น้อยหรือไม่มีผู้ป่วยคนนั้นอยู่ใน Time frames ที่เราเลือก ดังตารางที่ 8 เราจึงทำการสร้างข้อมูลให้ Time frames มีป่วยทุกคนคนละ 1 record จากนั้นทำการเติมข้อมูลแบบ ffill และ bfill เพื่อให้ข้อมูลใกล้เคียงความเป็นจริงโดยในแต่ละ Time frames จะมีผู้ป่วย Stroke และ Non-Stroke เท่ากันทุก

Time frames ดังตารางที่ 16

ผู้ป่วย	จำนวนผู้ป่วย

Stroke	2028
Non-Stroke	13217

ตารางที่ 16 จำนวนผู้ป่วยใน Time frames หลังทำขั้นตอนที่ 5

ขั้นตอน

1. เราสร้าง record เปล่า หากไม่มีข้อมูลในช่วงเวลานั้นหากผู้ป่วยรายใดไม่มีข้อมูลจริงใน Time frame ที่สนใจ (เช่น 3–6 เดือนก่อน stroke) จะสร้างแถวเปล่าขึ้นมาพร้อมวันที่สุ่มในช่วงเวลาเป้าหมาย

2. ใช้ ffill และ bfill เติมข้อมูลใน record เปล่าเมื่อสร้าง record ขึ้นมาแล้วเราจะใช้ข้อมูลก่อนหน้า (ffill) และถัดไป (bfill) เพื่อเติมค่าต่าง ๆ ลงใน record เปล่านั้น โดยเราคิดว่าในความเป็นจริง ค่าที่ใกล้เคียงกันในช่วงใกล้เคียงจะไม่เปลี่ยนแปลงมากนัก เช่น BMI, ความดัน, smoke

    - หลักการเติม ffill และ bfill
        - Ffill ถ้าไม่มีข้อมูล record ถัดไปจะเติมด้วยข้อมูล record ก่อนหน้า
        - Bfill ถ้าไม่มีข้อมูล record ก่อนหน้าจะเติมด้วยข้อมูล record ภัดไปหน้า

หมายเหตุ หลังจากทำการเติม ffill และ bfill คนไข้บางคนไม่เคยตรวจบาง feature มาก่อนทำให้ไม่สามารถเติมได้ดังตารางที่ 17

ผู้ป่วย	จำนวน
Stroke ที่มี missing อย่างน้อย 1 feature	910 คน
Non-Stroke ที่มี missing อย่างน้อย 1 feature	5798 คน

ตารางที่ 17 จำนวนผู้ป่วยที่พบ missing อย่างน้อย 1 feature

หลักการเติม ffill bfill โดยเราจะจำแนกประเภทของข้อมูลก่อนโดยสามารถแบ่งออกเป็น categorical ได้แก่ drinking, smoke, AF, sex และ numerical ได้แก่ LDL, bmi, FBS, eGFR, HDL, bpd, bps
โดยก่อนเลือก Time frame เราจำทำการเติม ffill และ bfill เติมข้อมูลของคนไข้คนนั้นก่อน

หมายเหตุ เราใช้เฉพาะข้อมูลของคนไข้คนนั้นเท่านั้นในการเติม

จากนั้นทำการเลือก Time frame ที่สนใจเช่น ช่วง 3-6 เดือน ต่อมาเราจะทำการตรวจสอบผู้ป่วยแต่ละคนว่ามีข้อมูลใน Time frame นั้นมั้ย ถ้าผู้ป่วยคนนั้นมี 1 record ใช้ได้เลย และ ถ้าผู้ป่วยคนนั้นมีมมากกว่า 1 record เราจะใช้ข้อมูลล่าสุด แต่ในกรณีที่ผู้ป่วยคนนั้นไม่มีข้อมูลในช่วงเวลาดังกล่าวเราจะสร้างข้อมูลตัวแทนในช่วงนี้นผลเติมด้วย ffill bfill โดยการใช้ ffill bfill เราจะใช้กับข้อมูลประเภท numerical และ categorical บางตัวได้แก่
AF, sex ส่วน drinking, smoke เราจะเติมโดยถ้า record ก่อนและหลังเท่ากันเราจะเติมค่านั้นทันทีถ้าไม่เท่ากะกันเราจะใช้ bfill ในการเติม

เราได้ทำการจตรวจสอบจำนวนจำนวนผู้ป่วยที่มี missing ในแต่ละ feature พบว่า
ดังตารางที่ 18

feature	Stroke	Stroke (%)	Non-Stroke	Non-Stroke (%)	All	All (%)
LDL	507	25.00%	1665	12.60%	2172	14.25%
bmi	0	0.00 %	0	0.00 %	0	0.00 %
FBS	551	27.17%	2250	17.02%	2801	18.37%
eGFR	444	21.89%	1558	11.79%	2002	13.13%
HDL	512	25.25%	1644	12.44%	2156	14.14%
bpd	0	0.00%	0	0.00 %	0	0.00%
bps	0	0.00%	0	0.00 %	0	0.00%
drinking	15	0.74%	623	4.71%	638	4.18%
smoke	15	0.74%	622	4.71%	637	4.18%
AF	413	20.36%	3618	27.37%	4031	26.44%
sex	0	0.00%	0	0.00%	0	0.00%

ตารางที่ 18 จำนวนผู้ป่วยที่มี missing ในแต่ละ feature

ข้อมูลผู้ป่วยที่มียังคงมี missing https://shorturl.asia/0mn2R

6 . Add Feature (stroke_target) โดย stroke = 1 และ Non-Stroke = 0 เพื่อให้ model สามารถรู้ได้ว่า class ไหน stroke หรือ Non-Stroke

7 . Concat file รวมไฟล์ stroke และ Non-Stroke ที่ผ่านการทำขั้นตอนทั้ง 6 ขั้นตอน เพื่อเข้า model

8. Split ข้อมูล โดยแบ่งเป็น train 80% test 20%

9. Classification model (XGboost) เนื่องจากสัดส่วนผู้ป่วย stroke และ Non-Stroke ต่างกันมากเราจึงใช้ Class weight เพื่อให้ Model เรียนรู้ได้ดีขึ้นและเพิ่ม 5 fold cross validation เพื่อเพิ่มความน่าเชื่อถือให้ผลลัพธ์

10. ตัวอย่างผลลัพธ์ 3 month time frame ดังรูปที่ 3

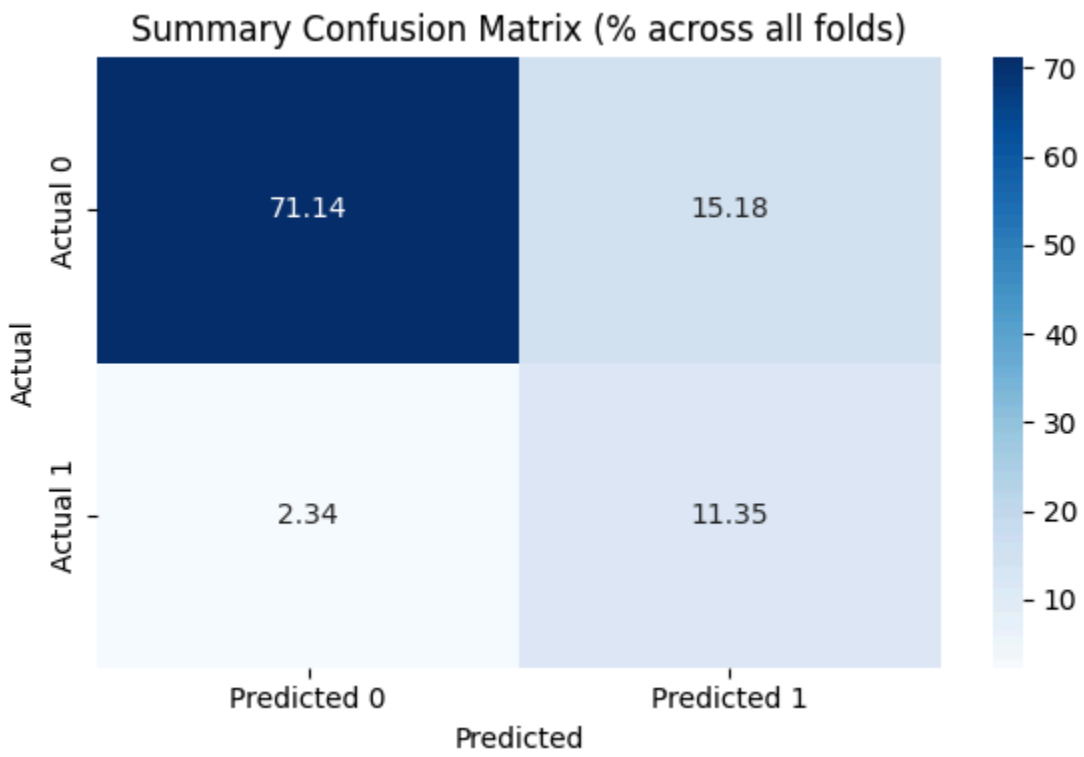

\

รูปที่ 3 Summary Confusion Matrix

ผลลัพธ์
Accuracy: 73.38% (± 0.82%)
Sensitivity: 44.94% (± 2.33%)
Specificity: 77.89% (± 0.95%)

ANOVA F-test Feature Ranking ทำการจัด Rank Feature ได้ผลลัพธ์ดังรูปที่ 4

	Feature	F_score	p_value	Rank
0	LDL	204.239264	7.197923e-46	1
4	HDL	159.388320	2.954910e-36	2
3	eGFR	136.430145	2.595429e-31	3
8	smoke	110.152619	1.242309e-25	4
1	bmi	94.468921	3.140027e-22	5
7	drinking	83.007377	9.785202e-20	6
6	bps	68.249920	1.627702e-16	7
2	FBS	65.442800	6.695574e-16	8
10	sex	45.432507	1.669303e-11	9
9	AF	33.688014	6.671675e-09	10
5	bpd	2.211176	1.370465e-01	11

รูปที่ 4 ANOVA F-test Feature Ranking

หมายเหตุ เนื่องจากคนไข้บางคนไม่เคยตรวจค่านั้นจริงๆทำให้ไม่สามารถเติมได้เราจึงได้ซึ่งส่งผลทำให้ทำ F ANOVA ไม่ได้ เราจึงทำการเติม -1 เพื่อให้ model มองเป็น missing ไปเลยเพราะการเติม 0 อาจทำให้ model เข้าใจว่า 0 เป็นค่าต่ำสุด

Model LSTM ver. BETA Preprocessing

อธิบายการทำ Preprocessing

รูปที่ 1 Flow chart preprocessing

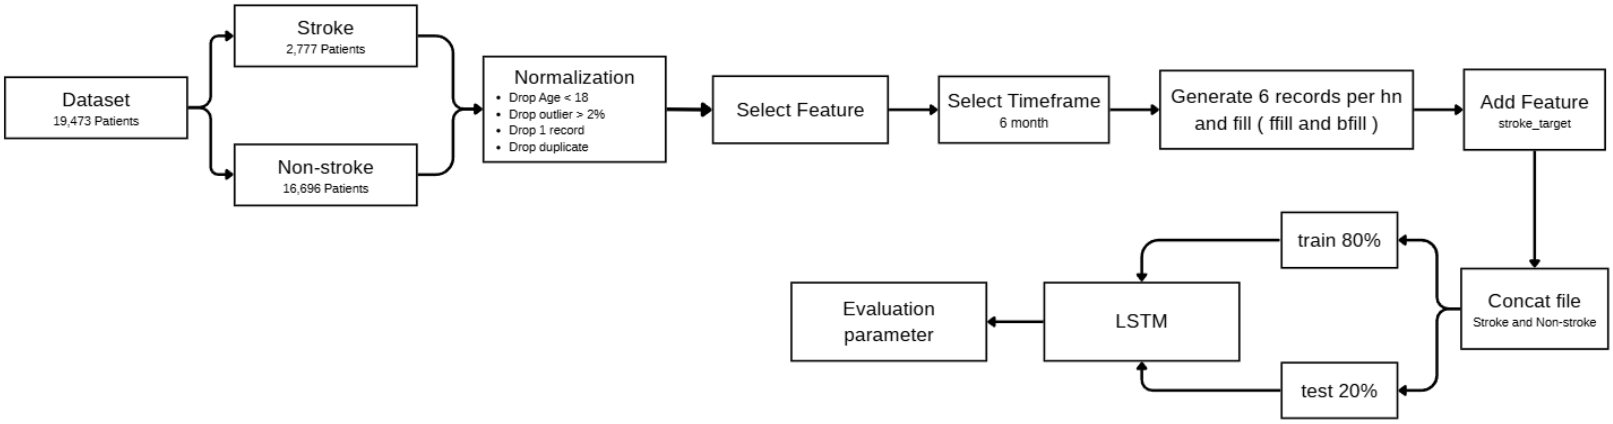


```
RandomForestClassifier(
    n_estimators=100,
    max_depth=6,
    min_samples_split=10,
    min_samples_leaf=5,
    max_features='sqrt',
    class_weight='balanced_subsample',
    n_jobs=-1
)
```

`n_estimators=100`	จำนวนต้นไม้	สร้างสุ่ม 100 ต้นไม้ในป่า ใช้รวมกันตัดสินผล

`max_depth=6`	ความลึกสูงสุดของต้นไม้	จำกัดความซับซ้อนของแต่ละต้นไม้ ป้องกัน overfitting
`min_samples_split=10`	จำนวน sample ขั้นต่ำก่อนแตก node	node จะไม่ถูกแบ่งถ้ามีน้อยกว่า 10 ตัวอย่าง
`min_samples_leaf=5`	จำนวน sample ขั้นต่ำในใบไม้ (leaf)	ใบสุดท้ายจะต้องมีอย่างน้อย 5 ตัวอย่าง
`max_features='sqrt'`	จำนวน feature ที่ใช้ตอนตัดแต่ละ node	ใช้ `√n_features` เพื่อให้แต่ละต้นไม้แตกต่างกัน
`class_weight='balanced_subsample'`	ปรับน้ำหนัก class อัตโนมัติ	ช่วยแก้ปัญหา **class imbalance** โดยพิจารณาจากสัดส่วนในแต่ละ sample ของต้นไม้

`Logistic Regression`

ใช้ `StandardScaler()` ปรับขนาดข้อมูลให้ mean = 0, std = 1
→ ช่วยให้ Logistic Regression ทำงานได้แม่นยำและเสถียรมากขึ้น

Regularization คือเทคนิคที่ใช้ใน **การฝึกโมเดล machine learning** เพื่อ **ลดการ overfitting** (คือ โมเดลเรียนรู้ข้อมูล training ดีเกินไปจนไม่แม่นกับข้อมูลใหม่)
`GridSearchCV` เพื่อหาค่าที่ดีที่สุดของพารามิเตอร์ เช่น:

- `C`: ควบคุมความแรงของการ regularization
- `penalty`: ใช้ L1 หรือ L2
- `class_weight='balanced'`: ช่วยปรับสมดุลระหว่างกลุ่ม stroke และ non-stroke

ใช้ **5-fold cross-validation** และวัดผลด้วย **F1-score** เพื่อเลือกค่าที่ดีที่สุด

Regularization คือเทคนิคที่ใช้ใน **การฝึกโมเดล machine learning** เพื่อ **ลดการ overfitting** (คือ โมเดลเรียนรู้ข้อมูล training ดีเกินไปจนไม่แม่นกับข้อมูลใหม่)

Feature	Stroke	Stroke (records)	Non stroke	Non stroke (records)	All	All (records)
LDL	562		481	9551	8481	10113
HDL	480	550	7967	9471	8447	10032
bps	598	2044	10205	32546	10803	34590
bpd	598	2044	10205	32546	10803	34590
eGFR	492	723	8306	12323	8798	13046
creatinine	546	795	8480	12550	9026	13345
AF	613	2044	7756	25755	8369	27799
EKG	703	2238	10545	33247	11248	35485
FBS	424	550	6712	8448	7136	8998

ช่วง 3-15 เดือนก่อนเป็น stroke

EKG_Category Count

- 218772 มีแค่ - นอกเหนือจากนั้นไม่มีครับ

ช่วง 3-15 เดือนก่อนเป็น stroke

AF			
Feature	Stroke	Non stroke	All
1 Record	206	1885	2091
2 Record	75	1016	1091
3 Record	87	1626	1713
< 3 Record	245	3229	3474

bps			
Feature	Stroke	Non stroke	All
1 Record	178	2648	2826
2 Record	71	1435	1506
3 Record	97	2175	2272
< 3 Record	252	3947	4199

bpd			
Feature	Stroke	Non stroke	All
1 Record	178	2648	2826
2 Record	71	1435	1506
3 Record	97	2175	2272
< 3 Record	252	3947	4199

HDL			
Feature	Stroke	Non stroke	All
1 Record	410	6673	7083
2 Record	60	1146	1206
3 Record	9	95	104
< 3 Record	1	53	54

LDL			
Feature	Stroke	Non stroke	All
1 Record	409	6655	7064
2 Record	60	1159	1219
3 Record	8	95	103
< 3 Record	1	55	56

creatinine			
Feature	Stroke	Non stroke	All
1 Record	408	6116	6524
2 Record	80	1507	1587
3 Record	28	393	421
< 3 Record	30	464	494

eGFR			
Feature	Stroke	Non stroke	All
1 Record	363	5977	6340
2 Record	76	1484	1560
3 Record	25	385	410
< 3 Record	28	460	488

FBS			
Feature	Stroke	Non stroke	All
1 Record	344	5461	5805
2 Record	59	973	1032
3 Record	9	145	154
< 3 Record	12	133	145

Triglyceride			
Feature	Stroke	Non stroke	All
1 Record	411	6678	7089
2 Record	60	1148	1208
3 Record	9	98	107
< 3 Record	1	53	54

ช่วง 9-15 เดือนก่อนเป็น stroke

AF			
Feature	Stroke	Non stroke	All
1 Record	171	2938	3109
2 Record	142	2239	2381
3 Record	46	762	808
< 3 Record	76	557	633

bps			
Feature	Stroke	Non stroke	All
1 Record	151	3853	4004
2 Record	152	2831	2983
3 Record	48	945	993
< 3 Record	73	644	717

bpd			
Feature	Stroke	Non stroke	All
1 Record	151	3853	4004
2 Record	152	2831	2983
3 Record	48	945	993
< 3 Record	73	644	717

HDL			
Feature	Stroke	Non stroke	All
1 Record	219	4251	4470
2 Record	26	354	380
3 Record	1	14	15
< 3 Record	0	6	6

LDL			
Feature	Stroke	Non stroke	All
1 Record	218	4258	4476
2 Record	25	351	376
3 Record	1	13	14
< 3 Record	0	6	6

creatinine			
Feature	Stroke	Non stroke	All
1 Record	242	4319	4561
2 Record	42	684	726
3 Record	14	115	129
< 3 Record	2	75	77

eGFR			
Feature	Stroke	Non stroke	All
1 Record	218	4214	4432
2 Record	38	678	716
3 Record	13	113	126
< 3 Record	1	74	75

FBS			
Feature	Stroke	Non stroke	All
1 Record	188	3538	3726
2 Record	25	364	389
3 Record	2	46	48
< 3 Record	4	26	30

Triglyceride			
Feature	Stroke	Non stroke	All
1 Record	219	4256	4475
2 Record	26	354	380
3 Record	1	14	15
< 3 Record	0	6	6

ช่วง 3-9 เดือนก่อนเป็น stroke

AF			
Feature	Stroke	Non stroke	All
1 Record	179	1847	2026
2 Record	152	2912	3064
3 Record	64	846	910
< 3 Record	93	727	820

bps			
Feature	Stroke	Non stroke	All
1 Record	165	2598	2763
2 Record	164	3750	3914
3 Record	70	1104	1174
< 3 Record	90	856	946

bpd			
Feature	Stroke	Non stroke	All
1 Record	165	2598	2763
2 Record	164	3750	3914
3 Record	70	1104	1174
< 3 Record	90	856	946

HDL			
Feature	Stroke	Non stroke	All
1 Record	244	3585	3829
2 Record	20	400	420
3 Record	1	17	18
< 3 Record	0	5	5

LDL			
Feature	Stroke	Non stroke	All
1 Record	243	3590	3833
2 Record	20	407	427
3 Record	1	17	18
< 3 Record	0	4	4

creatinine			
Feature	Stroke	Non stroke	All
1 Record	259	3605	3864
2 Record	50	888	938
3 Record	13	165	178
< 3 Record	5	78	83

eGFR			
Feature	Stroke	Non stroke	All
1 Record	231	3542	3773
2 Record	49	878	927
3 Record	12	161	173
< 3 Record	5	77	82

FBS			
Feature	Stroke	Non stroke	All
1 Record	210	2879	3089
2 Record	25	430	455
3 Record	5	44	49
< 3 Record	3	18	21

Triglyceride			
Feature	Stroke	Non stroke	All
1 Record	245	3592	3837
2 Record	20	403	423
3 Record	1	17	18
< 3 Record	0	5	5

Time slot	Stroke	Non-Stroke	All
3–7 เดือนก่อน	472	7666	8138
7–11 เดือนก่อน	451	7456	7907
11–15 เดือนก่อน	393	7058	7451

ตารางจำนวน patient ใน Time slot

Time slot	Stroke	Non-Stroke	All
3–7 เดือนก่อน	156	2547	2703
7–11 เดือนก่อน	168	2415	2583
11–15 เดือนก่อน	144	2717	2861
รวมทั้งหมด	365	6031	6396

ตารางจำนวน patient ที่มีครบ AF, bps, bpd, Creatinine, eGFR

Feature	Stroke			Non-Stroke			All		
	3–7 เดือนก่อน	7–11 เดือนก่อน	11–15 เดือนก่อน	3–7 เดือนก่อน	7–11 เดือนก่อน	11–15 เดือนก่อน	3–7 เดือนก่อน	7–11 เดือนก่อน	11–15 เดือนก่อน
AF	424	405	360	5824	5661	5455	6,248	6,066	5,815
bps	426	409	351	7577	7310	6844	8,003	7,719	7,195
bpd	426	409	351	7577	7310	6844	8,003	7,719	7,195
Creatinine	224	230	205	3367	3335	3718	3,591	3,565	3,923
eGFR	203	212	186	3313	3282	3635	3,516	3,494	3,821

ตารางจำนวน patient ที่แค่ feature เดียว

All 13 feature

```
✅ Accuracy: 79.16% ± 1.51%
✅ Sensitivity: 30.14%
✅ Specificity: 82.90%
✅ AUC: 0.644
<ipython-input-30-2dc2d0f6c989>:120: UserWarning: Glyph 129518 (\N{ABACUS}) mi
  plt.tight_layout()
/usr/local/lib/python3.11/dist-packages/IPython/core/pylabtools.py:151: UserWa
  fig.canvas.print_figure(bytes_io, **kw)
```

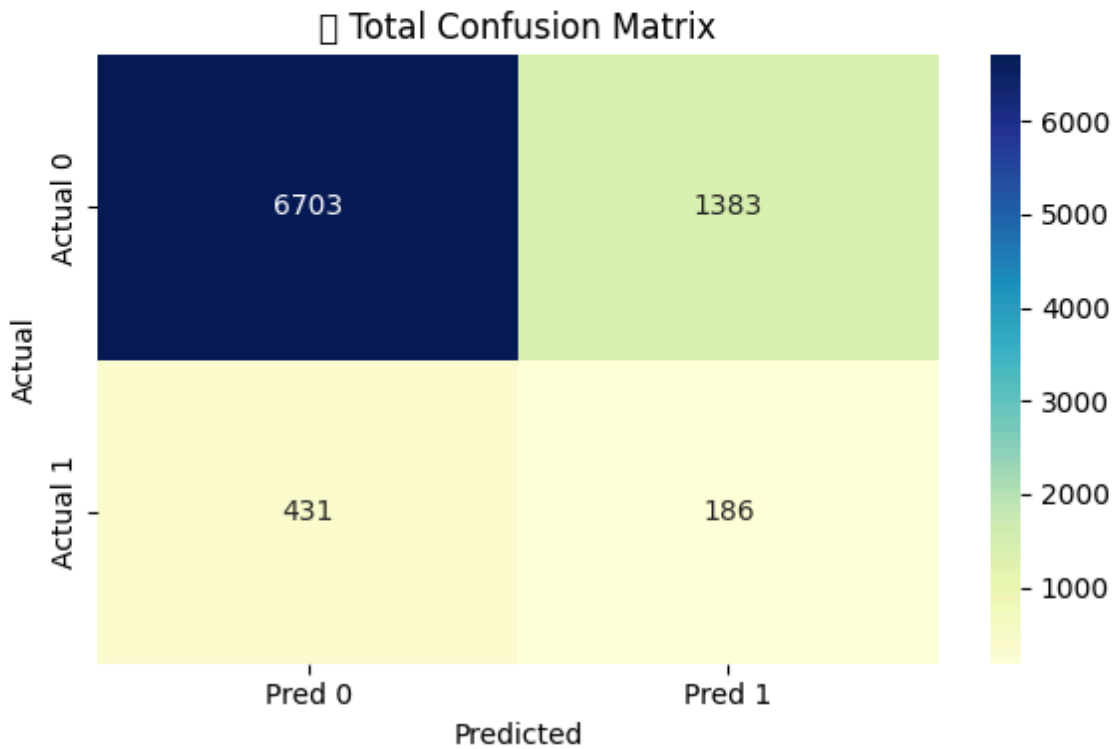

ข้อมูลหลัง drop +- 5 SD

	3-6 month	6-9 month	9-12 month	12-15 month
Stroke	406	386	362	336
Non stroke	7239	5933	6633	12637

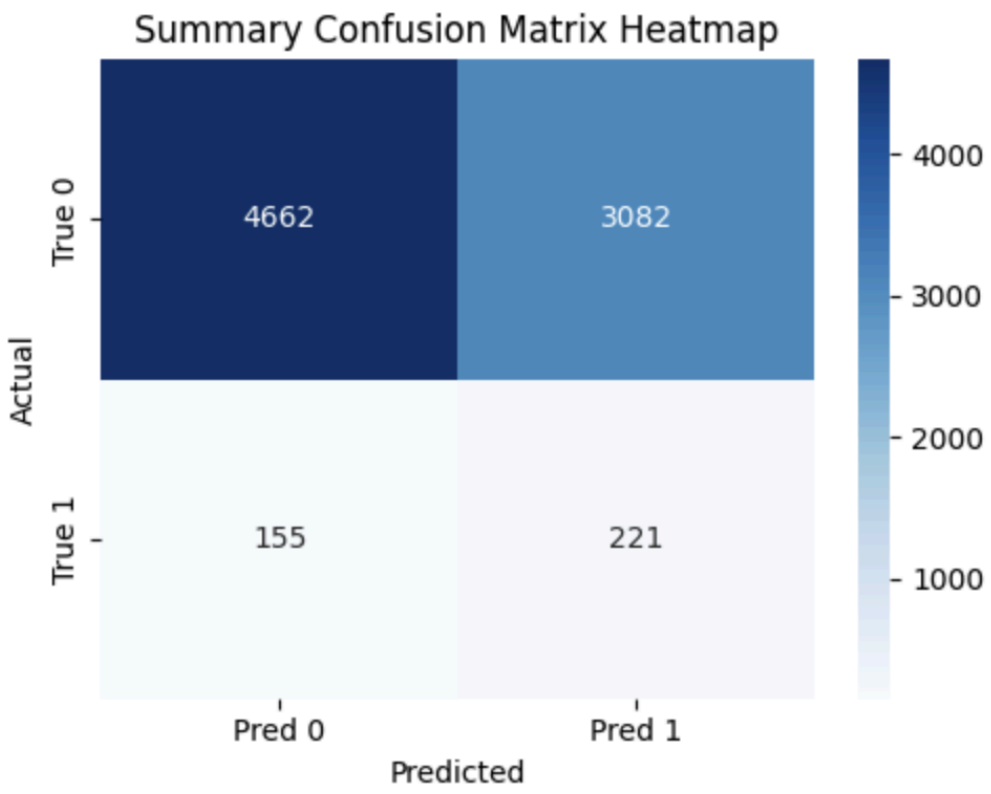

4 feature bmi bps bpd eGFR

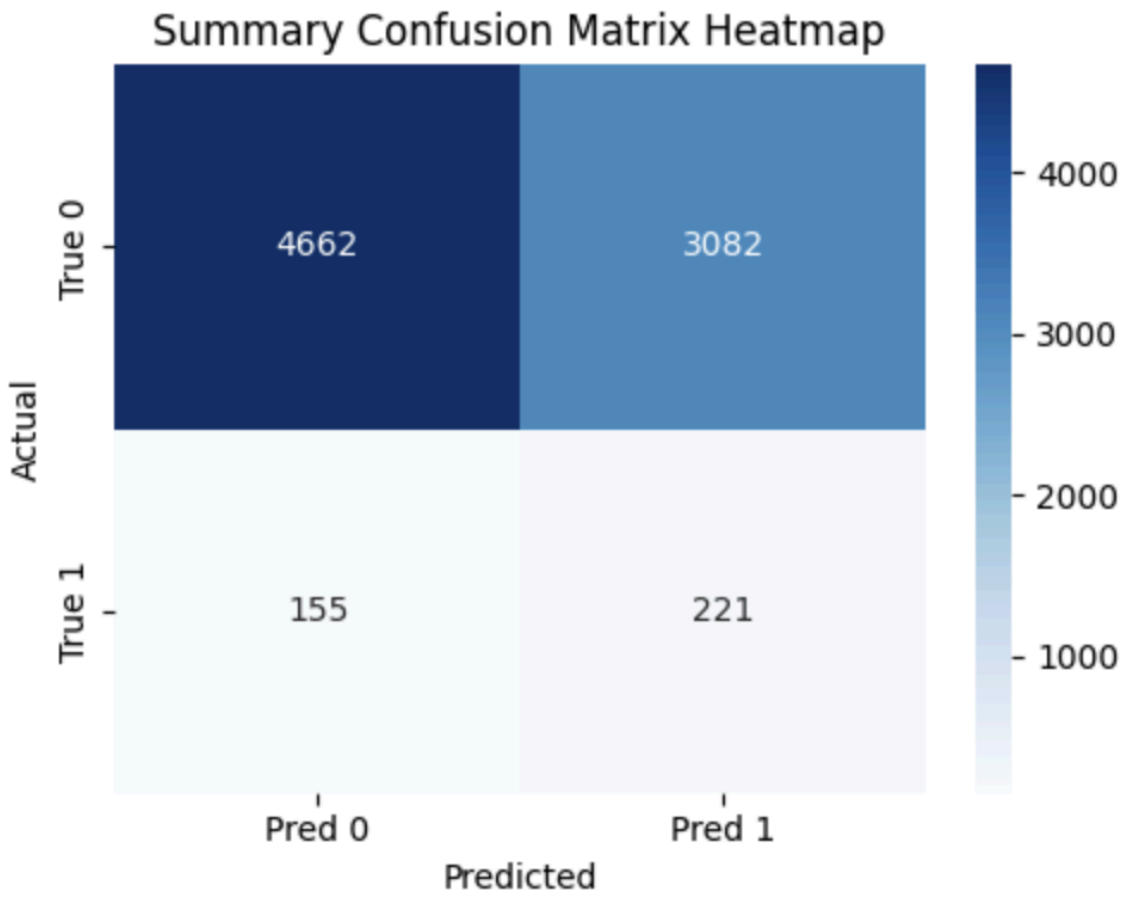

5 feature bmi bps bpd eGFR Creatinine

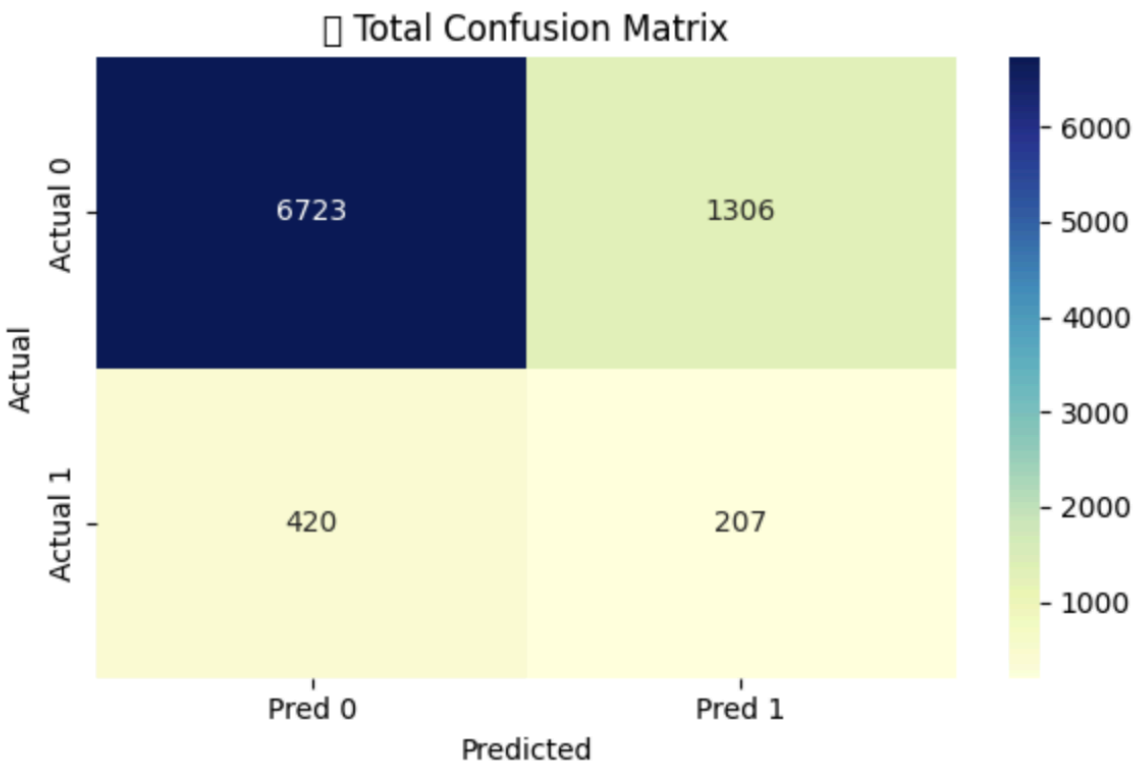

Model 3 month Selected ALL Features:

['Creatinine', 'bps', 'HDL', 'FBS', 'eGFR', 'AF', 'bpd', 'LDL', 'bmi', 'smoke', 'age', 'sex', 'drinking']

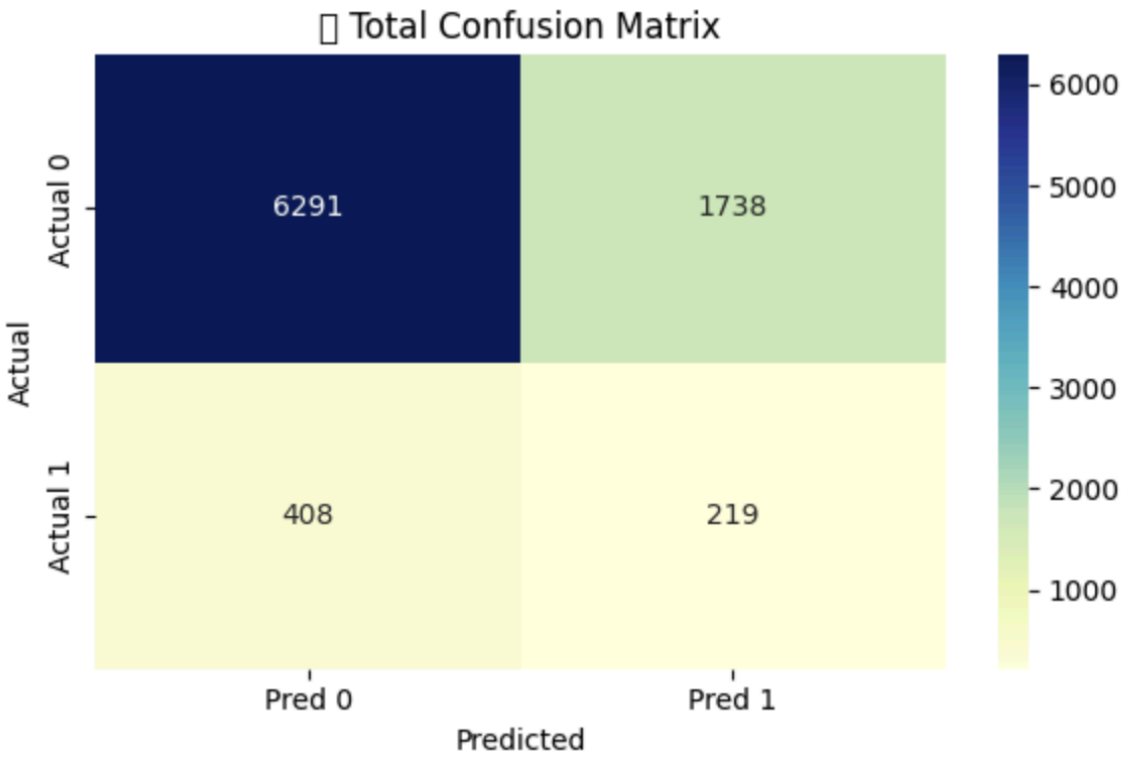

Model 3 month Selected Top 5 Features:

['Creatinine', 'bps', 'HDL', 'FBS', 'eGFR']

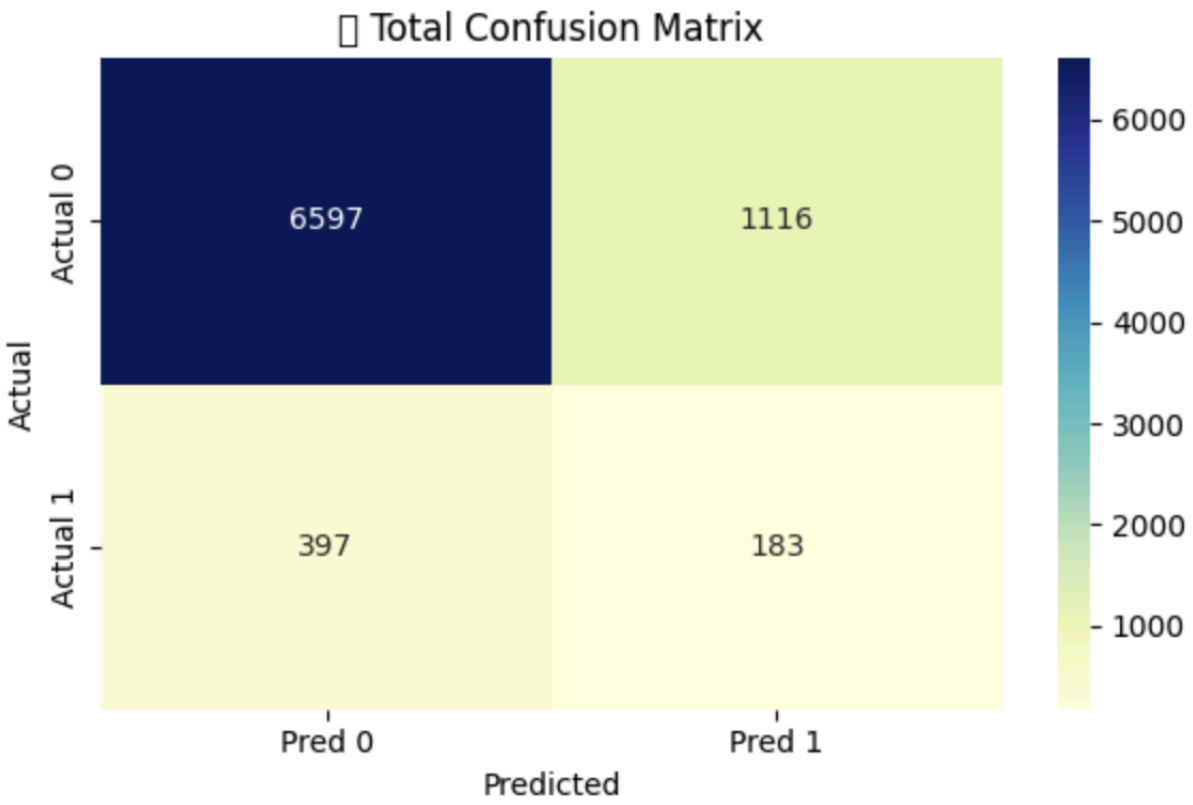

Model 6 month Selected ALL Features:

['bps', 'bmi', 'Creatinine', 'LDL', 'eGFR', 'bpd', 'FBS', 'HDL', 'age', 'sex', 'AF', 'drinking', 'smoke']

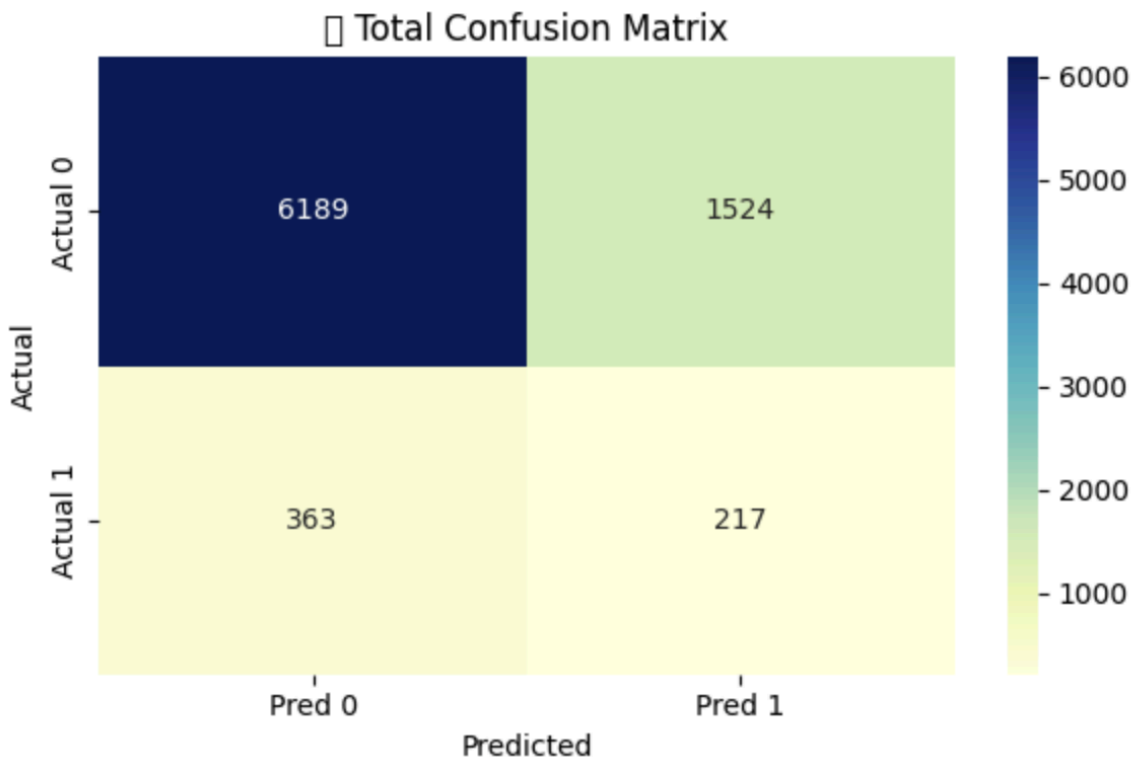

Model 6 month Selected Top 5 Features:

['bps', 'bmi', 'Creatinine', 'LDL', 'eGFR']

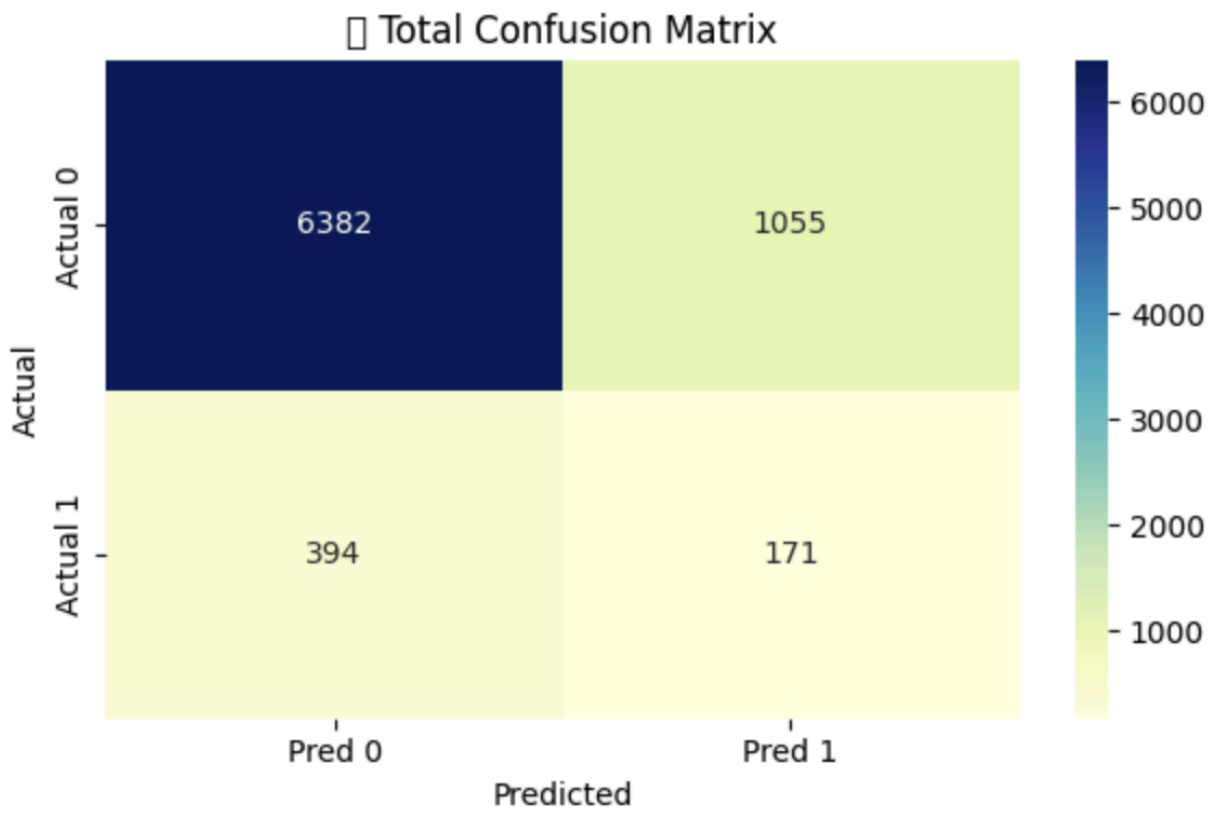

Model 9 month Selected ALL Features:

['bps', 'bmi', 'Creatinine', 'bpd', 'FBS', 'HDL', 'sex', 'age', 'LDL', 'eGFR', 'drinking', 'smoke', 'AF']

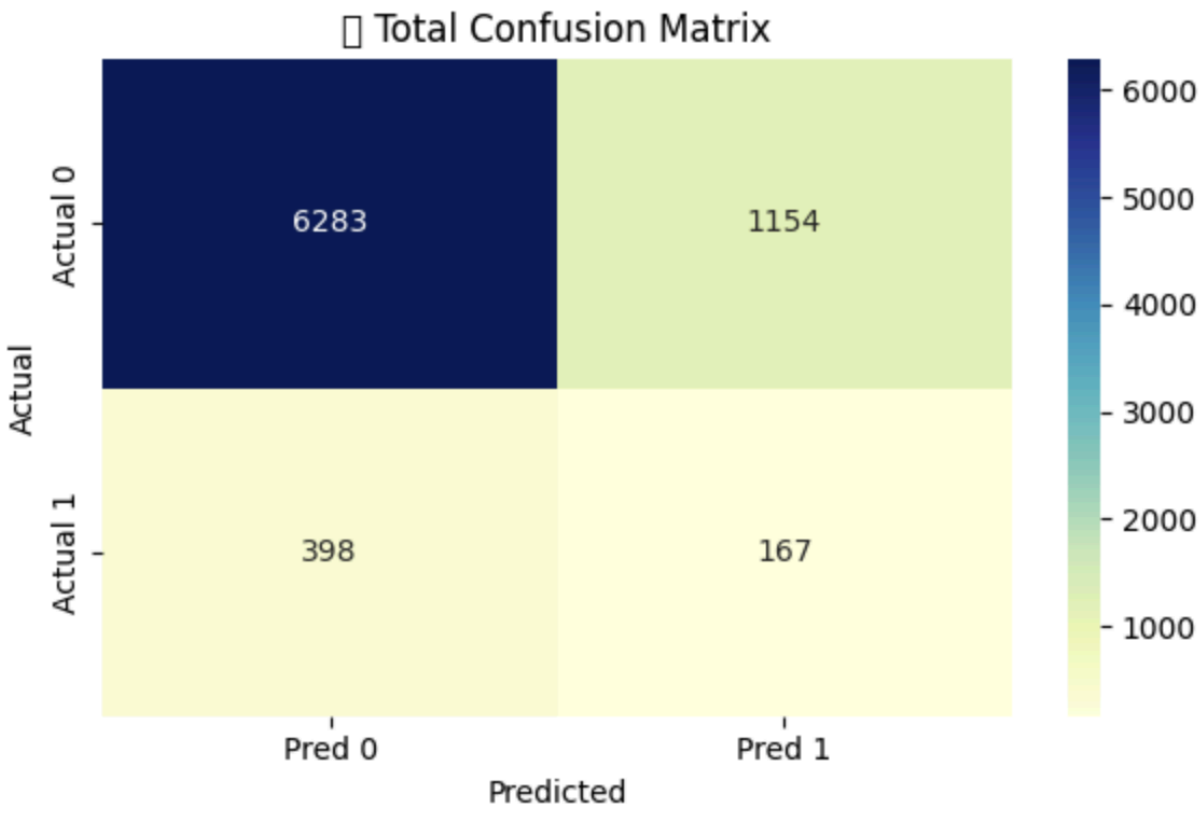

Model 9 month Selected Top 5 Features:

['bps', 'bmi', 'Creatinine', 'bpd', 'FBS']

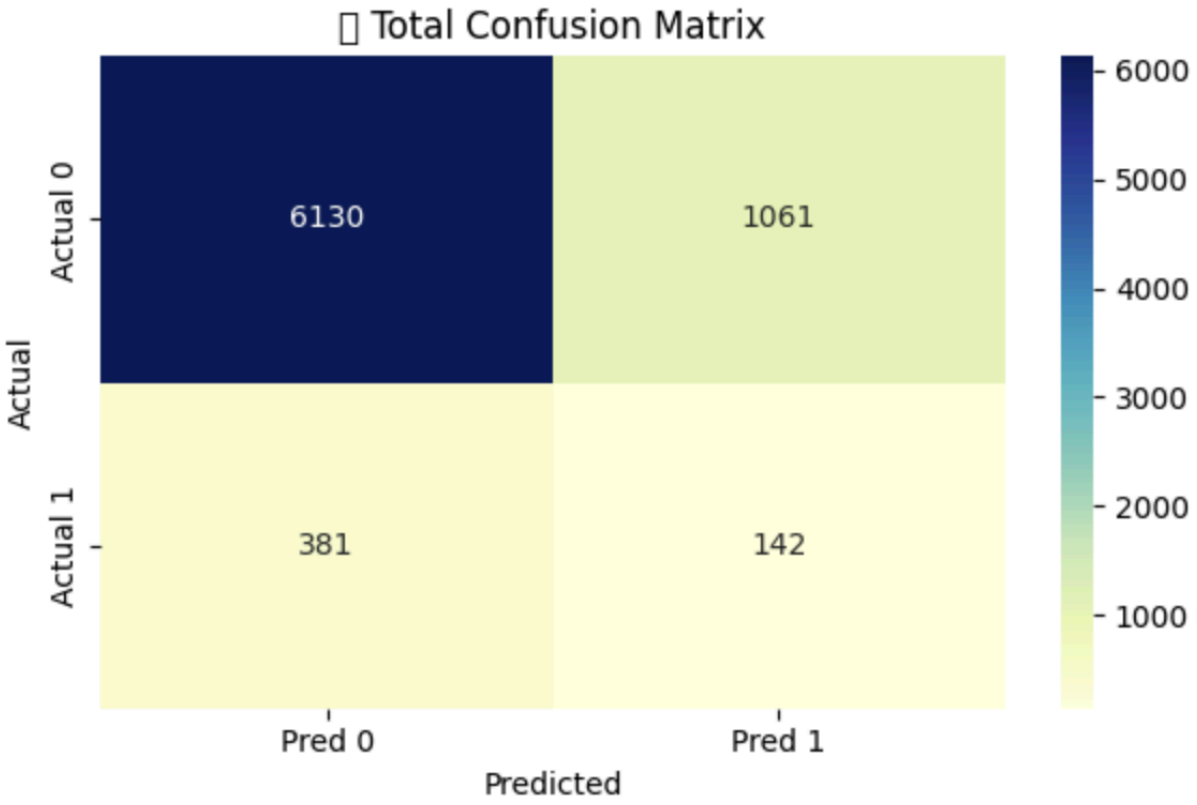

Model 12 month Selected ALL Features:

['Creatinine', 'bps', 'bmi', 'age', 'FBS', 'LDL', 'eGFR', 'sex', 'HDL', 'bpd', 'AF', 'drinking', 'smoke']

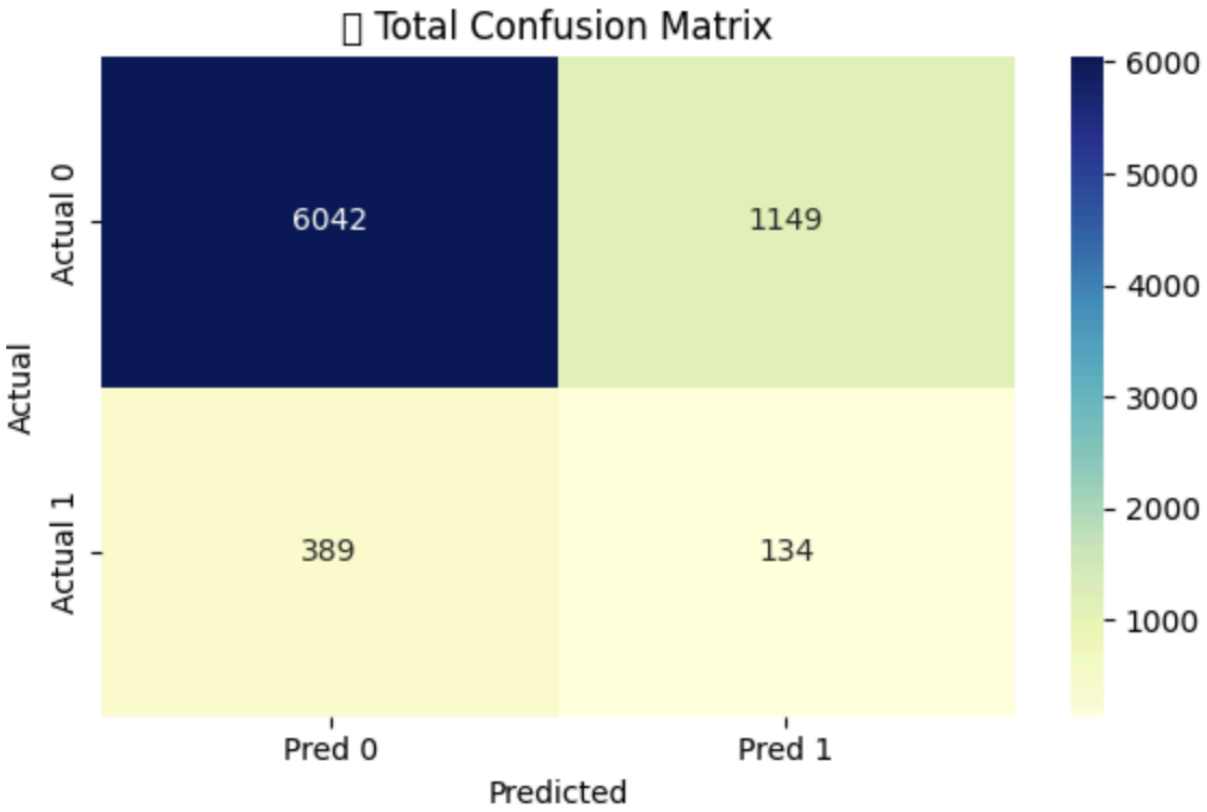

Model 12 month Selected Top 5 Features:

['Creatinine', 'bps', 'bmi', 'age', 'FBS']

ช่วงเวลา (เดือน)	กลุ่ม	visit 1 ครั้ง	visit 2 ครั้ง	visit 3 ครั้ง	visit ≥4 ครั้ง
3–6	HDL_LDL	2,259	187	1	0
	BPS_BPD	5,376	1,704	220	92
	eGFR_Creatinine	2,658	410	20	2
6–9	HDL_LDL	1,791	125	4	0
	BPS_BPD	4,540	1,231	169	92
	eGFR_Creatinine	2,222	279	25	12
9–12	HDL_LDL	2,589	160	4	0
	BPS_BPD	5,027	1,300	185	90
	eGFR_Creatinine	2,967	310	27	6
12–15	HDL_LDL	2,009	145	3	1
	BPS_BPD	4,135	1,088	136	64
	eGFR_Creatinine	2,284	268	25	9